

Из медиапотока в аналитику

Uzbek NER для Brand Analytics

Ценность: дать аналитикам структурированный узбекоязычный поток по организациям, людям и географии. Реализованы NER-сервис и интерфейс проверки текстов; целевое применение - интеграция в Brand Analytics.

Пользователь и проблема

Основной пользователь: медиааналитик или PR-специалист, который готовит отчёт по бренду в Узбекистане. Заказчик интеграции - продуктовая и инженерная команда Brand Analytics.

По постановке кейса узбекскому потоку недостаёт промышленного NER. Пропуски делают отчёты неполными; лишние сущности создают шум и ручную чистку. Поиск по заранее известным словам не раскрывает всех новых участников обсуждения.

Уточнённая продуктовая гипотеза

Если выделять ORG / NAME / GEO до построения отчётов, сохраняя точную связь с исходным сообщением и обе письменности, аналитик сможет быстрее собрать и проверить список участников инфополя. Ожидаемый эффект: меньше ручных исправлений и времени при сопоставимой или лучшей полноте отчёта. Эффект ещё требует пилота.

Границы реализованного MVP

Подтверждено: обученные модели; пакетный инференс и JSONL с hash, классом и координатами; окна для длинных текстов; ансамбль 2 из 3, train-словарь и повторы; воспроизводимые эксперименты, проверки данных, журнал MLflow и анализ ошибок. HTTP-сервис, Docker и все три encoder-a в TensorRT BF16. Веб-интерфейс: ввод текста и файлов, подсветка сущностей, фильтры и экспорт JSON.

Не входит: интеграция в отчёты Brand Analytics, тональность, сведение разных написаний к одному объекту, дополнительные классы. Промышленный SLA и внедрение не заявляются.

Реализованный пользовательский сценарий

1. Пользователь открывает наш веб-интерфейс. 2. Вставляет текст, выбирает пример из датасета или загружает TXT / JSON / JSONL. 3. Запускает анализ: UI обращается к HTTP-сервису. 4. Проверяет подсвеченные ORG / NAME / GEO, фильтрует сущности и экспортирует ответы в JSON.

Следующий этап, не текущий MVP: подключить API к потоку Brand Analytics и использовать упоминания в отчётах. UI служит проверке результата; сбор медиапотока и отчётная аналитика в нашем MVP не реализованы.

Вклад AI Product: выбран конкретный рабочий сценарий, отделён NER-модуль от отчётного продукта и ограничен объём MVP.