

Что доказано на хакатоне

Качество модели отдельно от бизнес-эффекта

Техническая часть гипотезы подтверждена: получен измеримый прирост качества извлечения. Экономия времени аналитика, стоимость промышленной обработки и влияние на клиентские KPI пока не измерены.

Способ проверки

Один exact-span evaluator: совпадают hash, класс, начало и конец. Official train - 13 000, dev - 1 500 текстов; public - 1 000. В таблице dev не включён в обучение моделей или словарь. Сравнение показывает результат отбора, а не независимую оценку: dev и лидерборд использовались неоднократно.

Проверенный вариант	Dev F1	Public F1
Baseline организаторов, b00	0,7897	не замерен
Одиночная модель + silver, s45	0,9096	0,8768
Ансамбль 2 из 3, s62	0,9124	0,8861
s62 + точные повторы	0,9152	0,8897
s62 + train-словарь + повторы	0,9174	0,8922

Критерии успеха и статус

Качество: рост к baseline и контроль каждого класса. Для последнего варианта dev F1: ORG 0,8981; NAME 0,9305; GEO 0,9251. Micro-precision 0,9131; recall 0,9218. ORG остаётся приоритетом.

Воспроизводимость: сохранены конфиги, версии, data hashes, предсказания, метрики и MLflow-история. Для исходного s62 создан отдельный read-only снимок с SHA-256.

UI и поставка: веб-интерфейс подключён к ансамблю; официальный API-checker прошёл напрямую и через Nginx. 77 targeted тестов прошли; Docker проверен без сети и внешних файлов.

Нагрузка: A100 80 GB, driver 580.173.02, полный HTTP на одном хосте, без загрузки весов и прогрева в тайминге. 30 одиночных запросов/с без ошибок: public p95 0,59 с. Одиночный HTTP: dev 44,2 и public 40,3 сообщения/с.

Пользовательская польза: время подготовки отчёта и число ручных исправлений ещё не проверены с аналитиками. Прирост F1 сам по себе не доказывает экономию или рост выручки.

Какие решения подтвердили проверки

Все три encoder-а в TensorRT BF16: одиночный HTTP ускорился на 35,1% на dev и 28,4% на public. Dev F1 при batch=1: с 0,916667 до 0,917114; при batch=8: с 0,917410 до 0,917291. Это численное изменение, не полная эквивалентность. Public 0,8922 в таблице относится к архивной посылке, а не к новому Docker. Польза словаря на dev сосредоточена в одном документе; обобщение требует свежей выборки.

Вывод: качество, UI/API и короткий тест нагрузки проверены. Следующий шаг - целевое окружение, длительная нагрузка и пользовательский пилот.